

Gliederung der Vorlesung

- 1) Einführung und Grundlagen
- 2) Klassische Zeitreihenanalyse
 - a) Trendbestimmung
 - b) Glättung von Zeitreihen durch Filter (lokale Trendbestimmung)
 - c) Saisonbereinigung
 - d) Exponentielles Glätten, Prognosen
- 3) Modellierung von Reihen durch stochastische Prozesse
 - a) Autoregressive (AR) Modelle
 - b) Moving Average (MA) Modelle
 - c) ARMA Modelle
 - d) ARIMA Modelle

Das klassische Komponentenmodell

Komponentenmodelle für Zeitreihen gehen aus von einer Zerlegung der Form

$$x_t = m_t + s_t + u_t \quad (\text{additives Modell})$$

$$x_t = m_t \cdot s_t + u_t \quad (\text{quasimultiplikatives Modell})$$


$$x_t = m_t \cdot s_t \cdot u_t \quad (\text{multiplikatives Modell})$$

Dabei bezeichnen


- (m_t) den **Trend**: eine langfristige systemische Veränderung des mittleren Niveaus der Zeitreihe
- (s_t) die **Saison**: eine regelmäßige zyklische Schwankung mit Periode p , d.h. $s_{t+p} = s_t$ und $\sum_{k=1}^p s_k = 0$.
- (u_t) den **Rest**: nicht zu erklärende Einflüsse oder Störungen

Manchmal noch Konjunkturkomponente, Kalenderkomponente...

Wir schauen uns an:




Wir schauen uns an:



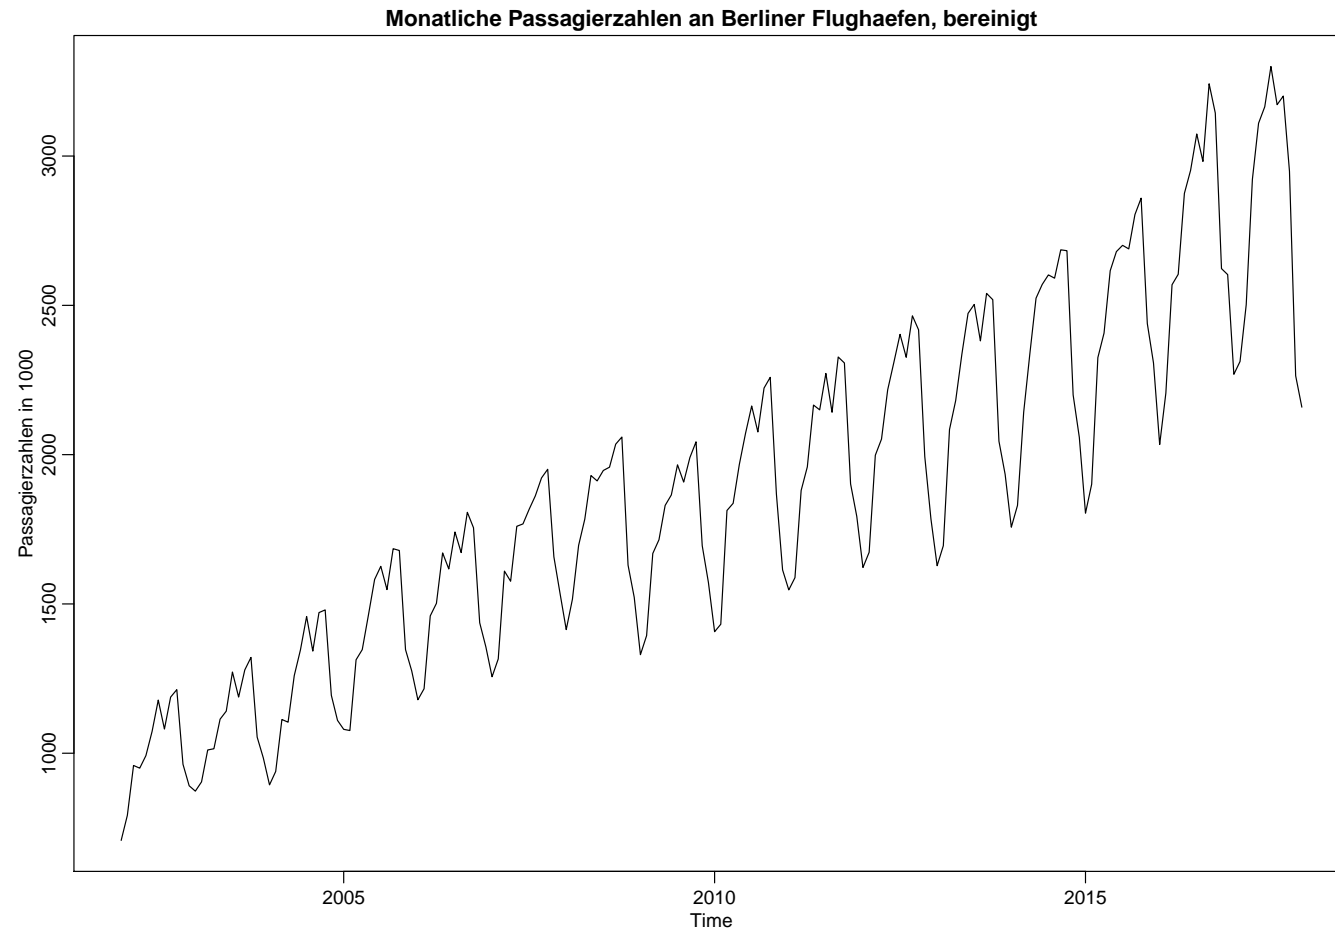
→ **Ausreißer!** April 2010, der Vulkan... Wir ersetzen den Wert durch den Mittelwert aus April 2009 und April 2011.

Wir schauen uns an:

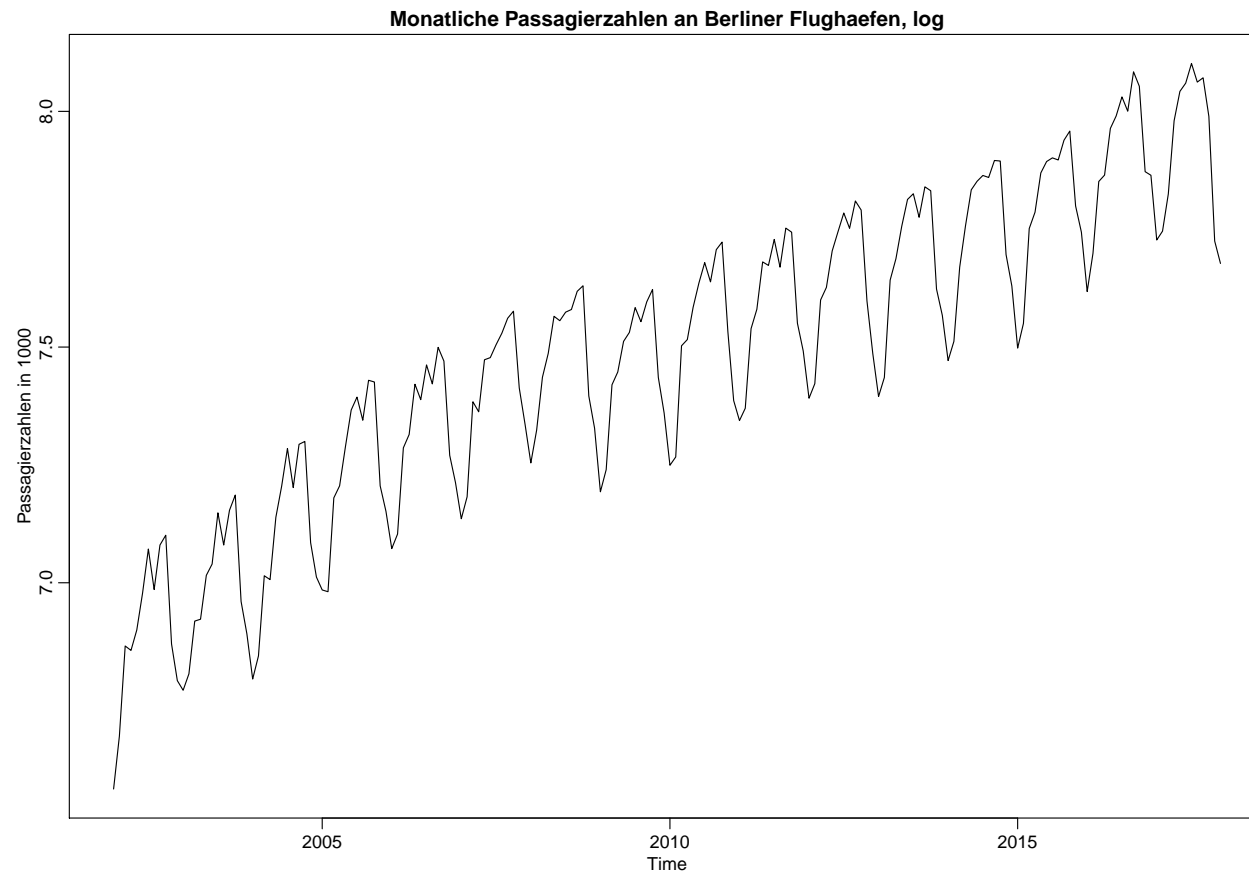


→ **Ausreißer!** April 2010, der Vulkan... Wir ersetzen den Wert durch den Mittelwert aus April 2009 und April 2011.

Wir schauen uns an:



Wir schauen uns an:




→ Schwankungen wachsen mit der Zeit → **Log nehmen!**
Dann sind wir bei einem additiven Modell.

Saisonbereinigung: Mehrere Möglichkeiten

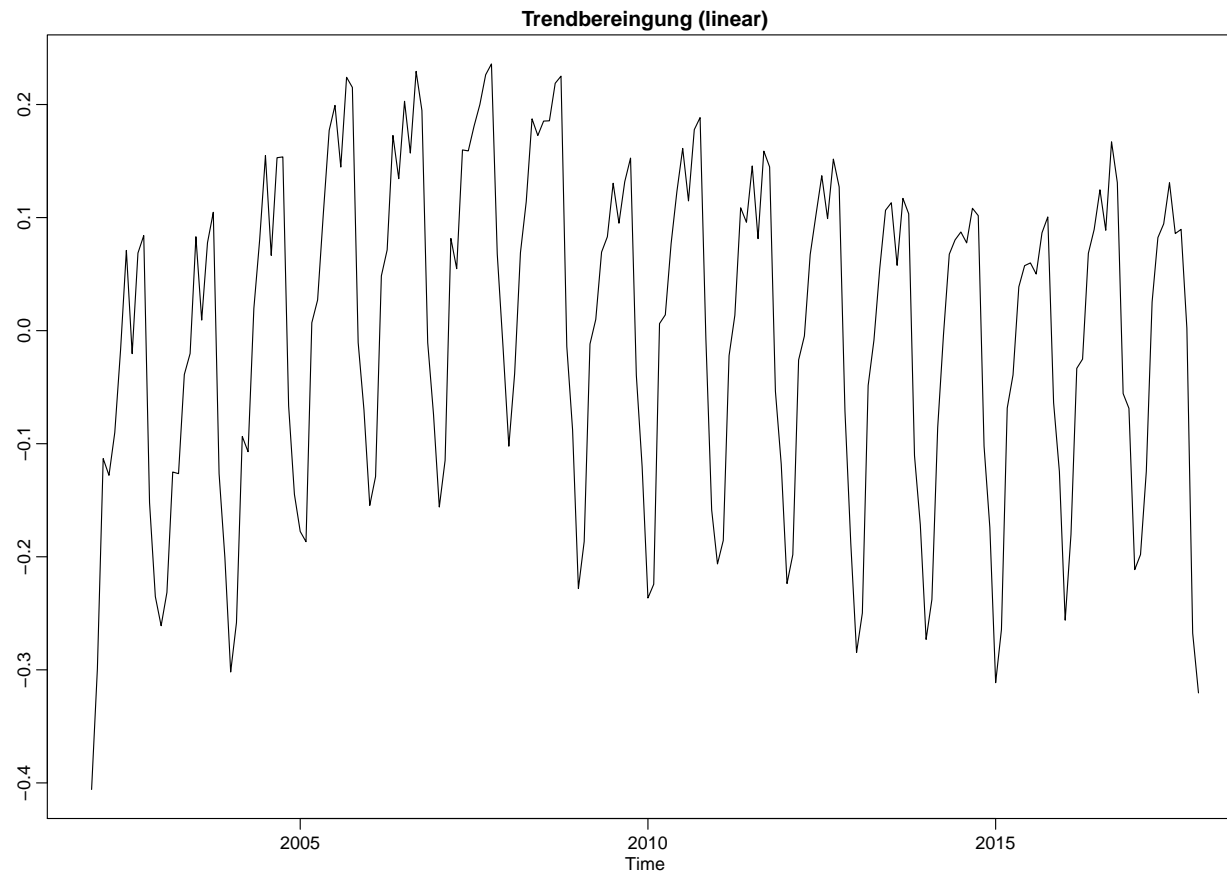
- Phasendurchschnittsverfahren
 - 1) Trend bestimmen und bereinigen (z.B. mit polynomialer Regression oder gleitenden Durchschnitten)
 - 2) Saisonkomponente als Durchschnitt der Phase über die Jahre
 - 3) Das Gesamtmodell aus Trend und Saison wieder zusammensetzen
- Regression mittels Saison-Dummies (eine Regression für beides, Trend und Saison)
- Regression mit trigonometrischen Polynomen
- Differenzenbildung (haben wir bereits gesehen)
- Viele etablierte Verfahren als Mischung aus diesen Methoden (und evt. noch anderen).

Phasendurchschnittsverfahren: Trend



Phasendurchschnittsverfahren: Saison

Saisonresiduen = Data - Trend



Phasendurchschnittsverfahren: Saison

$$r_k^j = \text{Saisonresiduen} = \text{Data} - \text{Trend}$$

- Über jeden Monat (Phase) $j = 1, \dots, 12$ über $k = \frac{N}{12}$ Jahre mitteln:

$$M_j = \frac{1}{k} \sum_{i=1}^k r_i^j$$

- Die gemittelten Werte zentrieren:

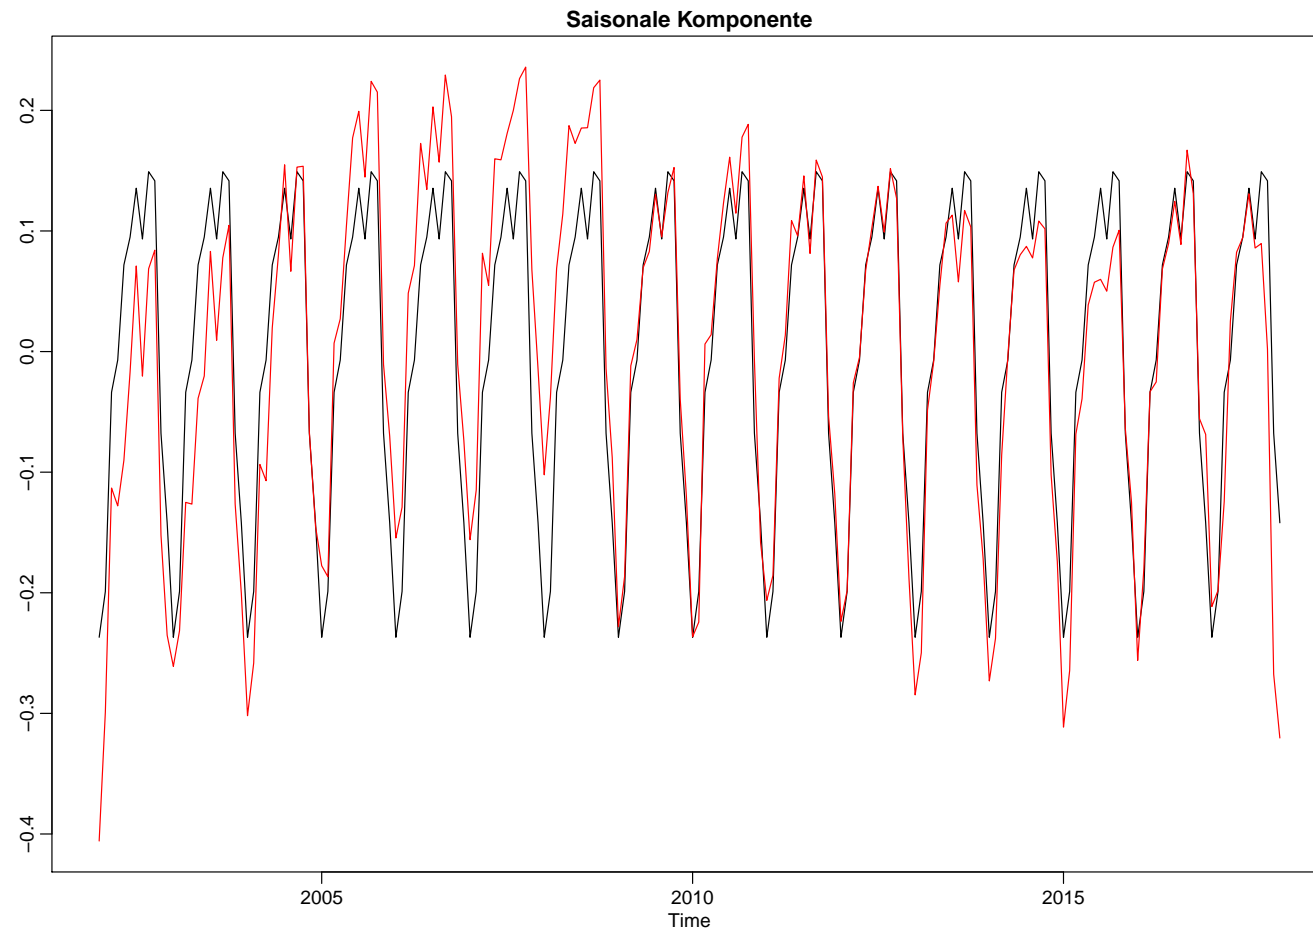
$$\bar{d} = \frac{1}{12} (M_1 + \dots + M_{12}), \quad S_j = M_j - \bar{d}, \quad j = 1, \dots, 12$$

- So erhalten wir 12 Saisonkomponenten S_1, \dots, S_{12} mit

$$S_1 + \dots + S_{12} = 0,$$

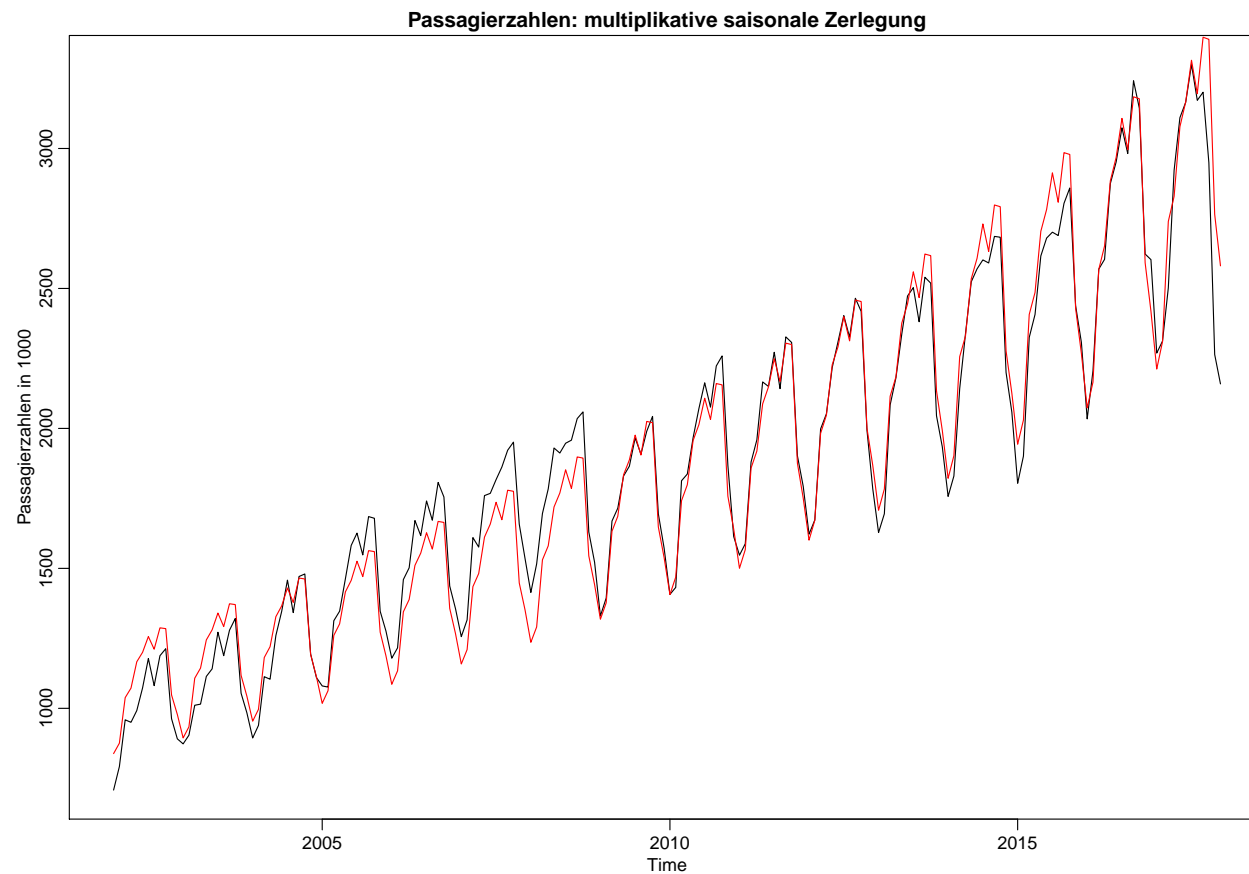
diese werden zu einer Reihe aus k Jahren fortgesetzt.

Phasendurchschnittsverfahren: Saison




Phasendurchschnittsverfahren: Modell

$$\text{Modell} = \text{Trend} + \text{Saison}$$




Phasendurchschnittsverfahren: Trend über gleitende Durchschnitte



→ Bessere Anpassung, aber fehlende Werte am Rand: Prognose?

Phasendurchschnittsverfahren: Trend über gleitende Durchschnitte

Berechnung wie bei dem polynomialen Trend oder direkt mit “decompose”



Regression mittels Saison-Dummies

Wir führen 12 Saisonvariablen

$$Q_i := \begin{cases} 1 & \text{für Monat } i \\ 0 & \text{sonst} \end{cases} \quad i = 1, \dots, 12$$

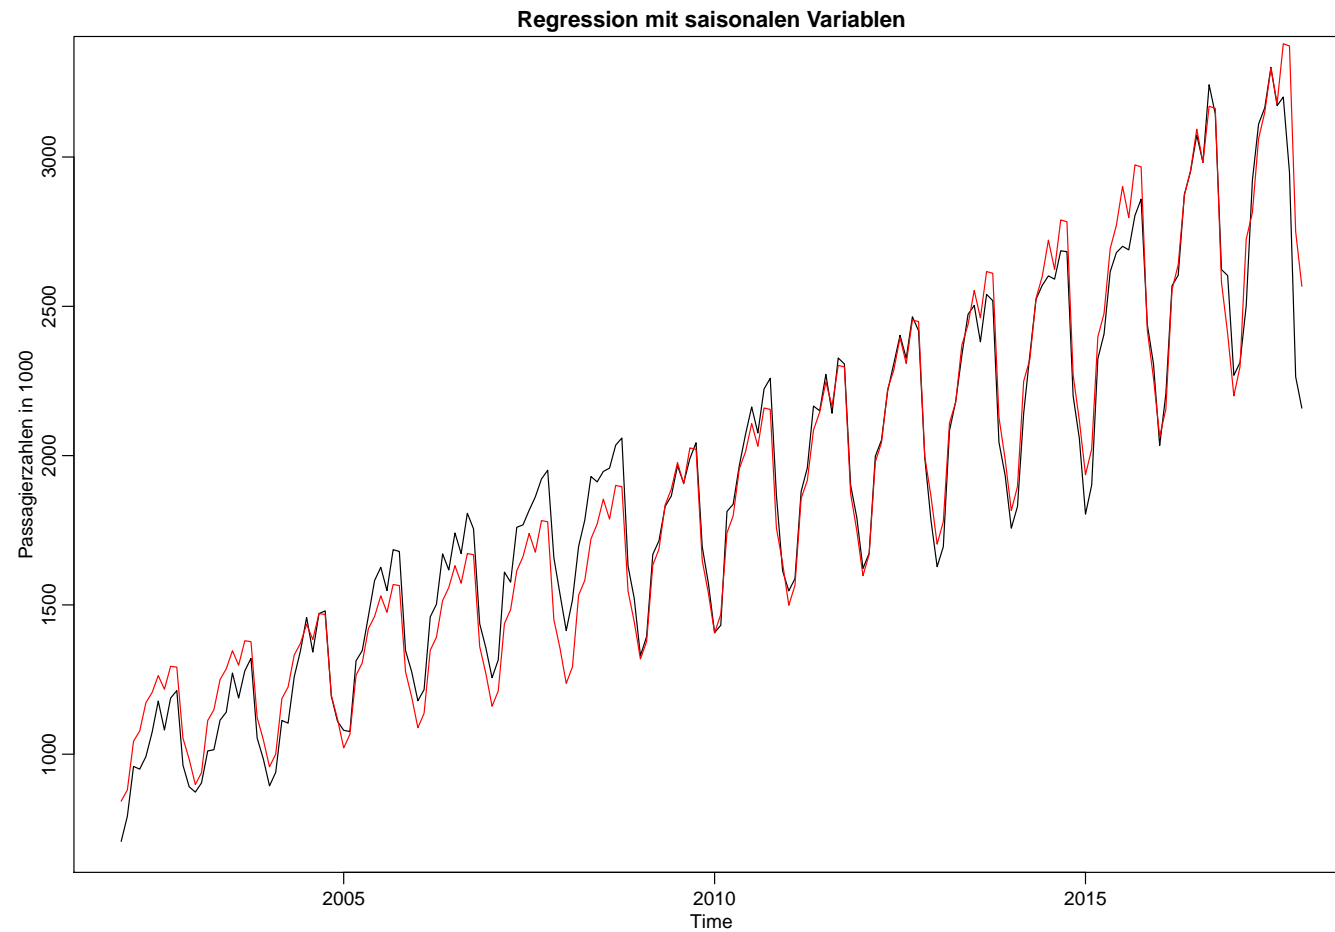
ein und machen einen (homogenen) Regressionsansatz

$$x_t = \beta_1 t + \beta_2 t^2 + \dots + \beta_n t^n + \alpha_1 Q_1 + \dots + \alpha_{12} Q_{12} + u_t.$$

(Inhomogen auch möglich, dann andere Interpretation der Koeffizienten.)

Vorteil: Trend und Saison werden gleichzeitig behandelt.

Regression mittels Saison-Dummies



Regression mit trigonometrischen Polynomen

Statt Saison-Dummies verwenden wir die Terme

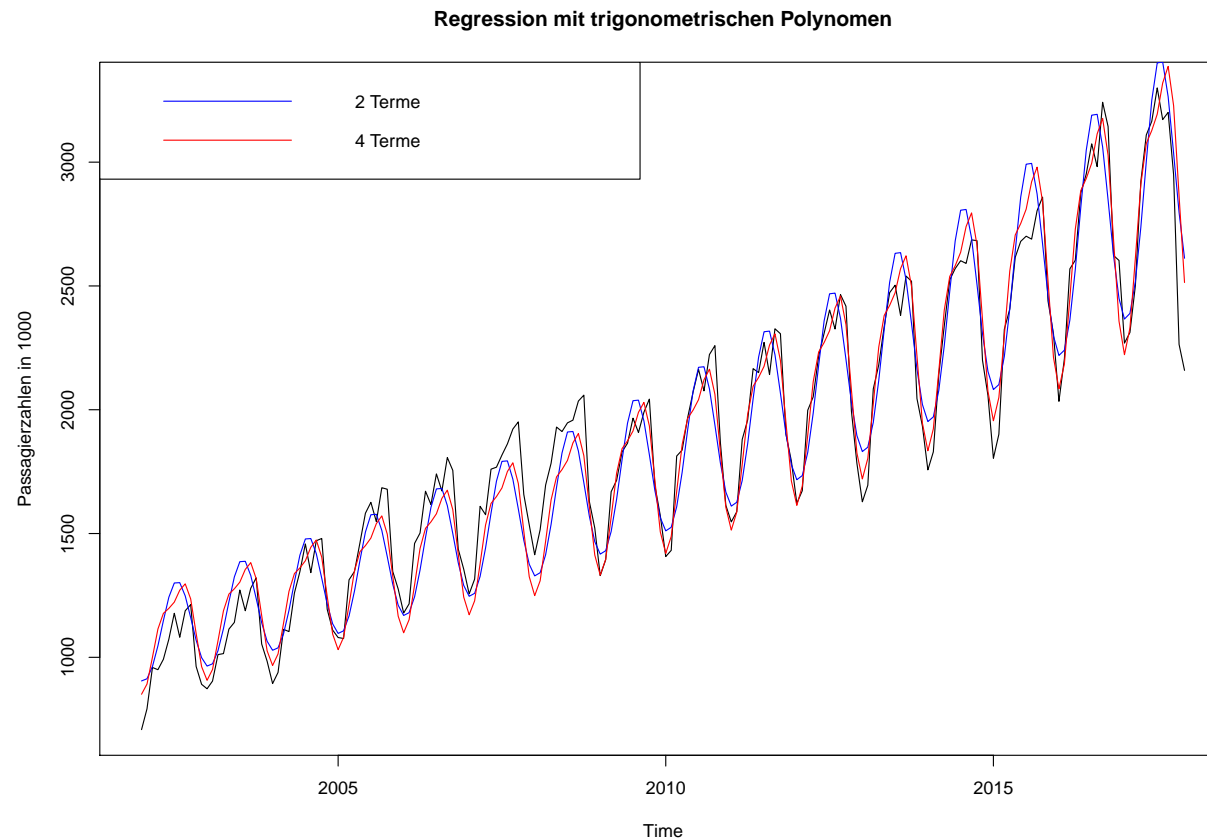
$$\cos\left(\frac{2\pi}{12}it\right), \quad \sin\left(\frac{2\pi}{12}it\right), \quad i = 1, \dots, 6.$$

Meistens reicht schon $i = 1$ (2 Terme), kompliziertere Saisonfiguren brauchen evt. mehr. Diese Terme sind periodisch mit Periode 12, für andere Perioden (z.B. Quartalszahlen) müssen sie entsprechend angepasst werden.

Wieder machen wir den Regressionsansatz

$$x_t = \beta_0 + \beta_1 t + \dots + \beta_n t^n + \sum_{i=1}^6 \left(\alpha_i \cos\left(\frac{2\pi}{12}it\right) + \phi_i \sin\left(\frac{2\pi}{12}it\right) \right).$$

Regression mit trigonometrischen Polynomen




Hier mit 2 Termen.

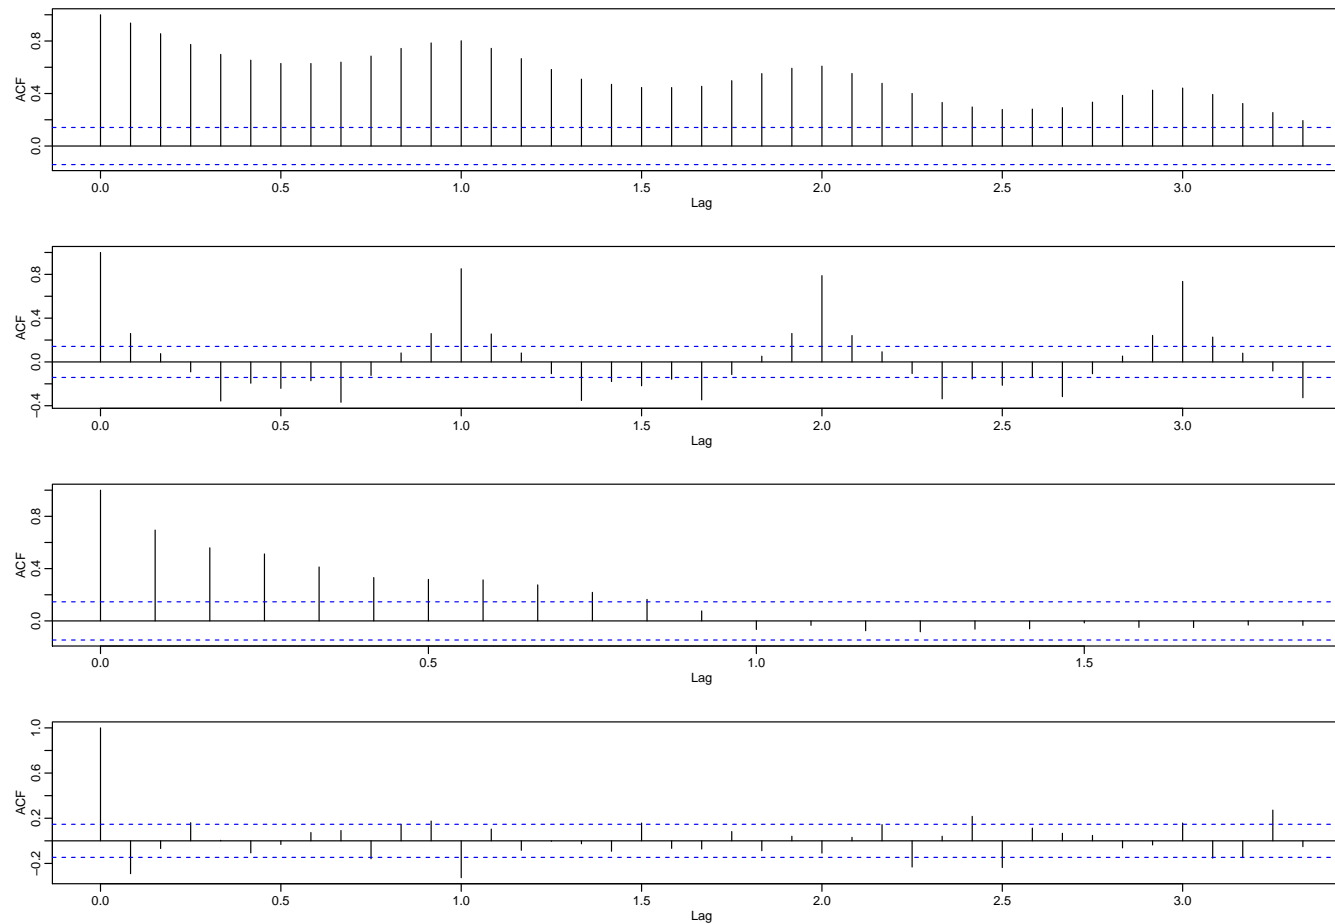
Vergleich der Modelle

```
> Rquadrat(mm, passb)
[1] 0.966658
> Rquadrat(mmg, passb)
[1] 0.9946772
> Rquadrat(exp(fitted.values(reg0)), passb)
[1] 0.9679645
> Rquadrat(exp(fitted.values(tfit)), passb)
[1] 0.940457
> Rquadrat(exp(fitted.values(tfit3a)), passb)
[1] 0.9604411
> AIC(reg0,tfit,tfit3a)
      df      AIC
reg0   14 -491.7374
tfit    5 -406.0068
tfit3a  7 -468.1257
> BIC(reg0,tfit,tfit3a)
      df      BIC
reg0   14 -446.1325
tfit    5 -389.7193
tfit3a  7 -445.3233
```

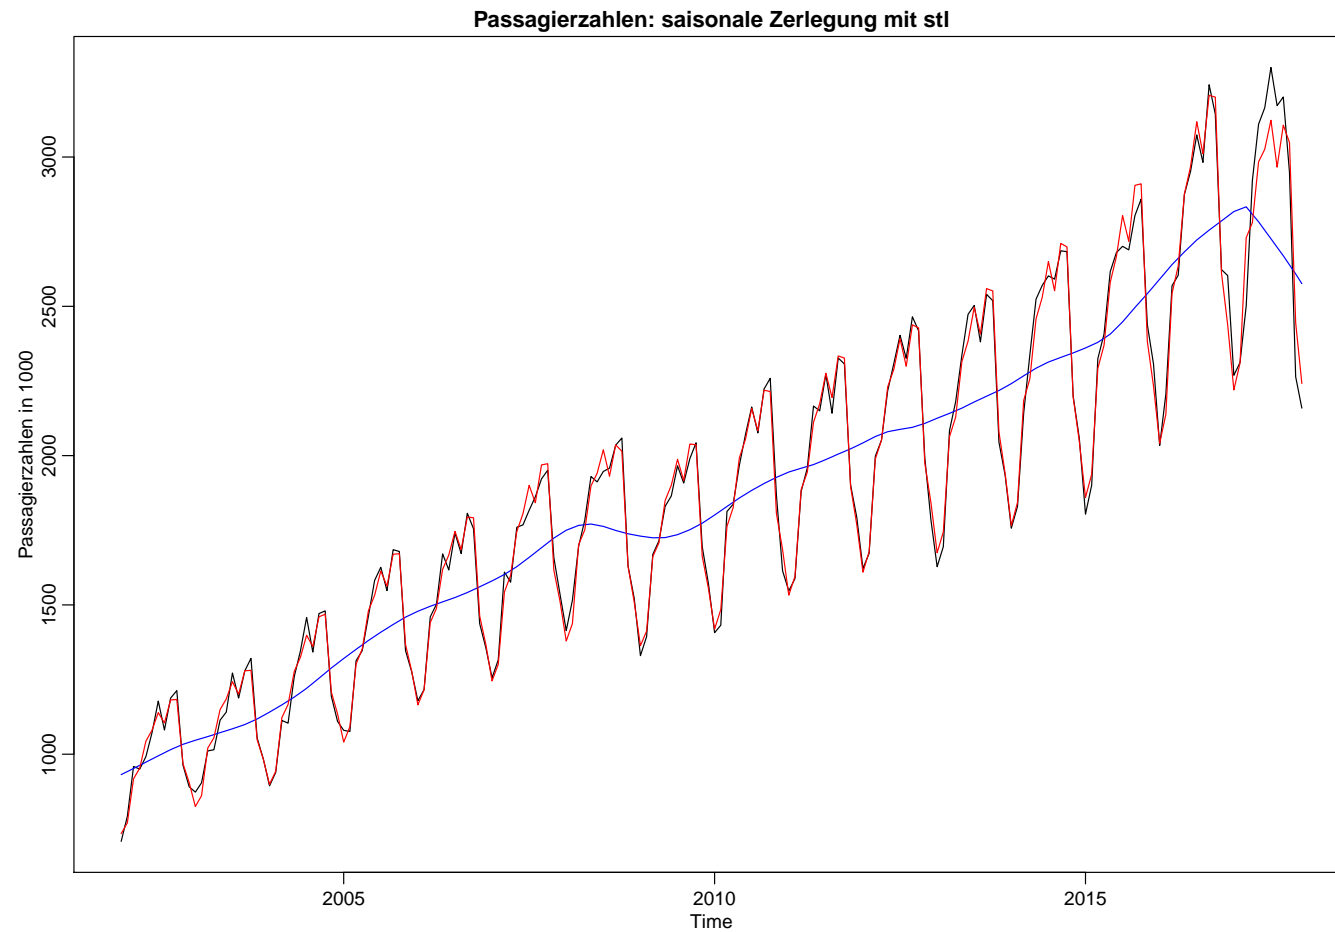
Saisonbereinigung durch Differenzenbildung



Saisonbereinigung durch Differenzenbildung



Zerlegung mit “stl”



Saisonbereinigung: Etablierte Verfahren

Berliner Verfahren BV4.1.

- Wird seit 2004 vom Statistischem Bundesamt verwendet
- Kostenloser Download unter <https://www.destatis.de/DE/Methoden/Zeitreihen/SoftwareZeitreihenanalyse.html>
- Zuerst (nach Wunsch) Kalender- bzw. Ausreißerbereinigung
- Schätzung des Trends lokal mit Polynomen 3. Grades, am Rand mit hohem linearen Anteil ("Randfilter")
- Schätzung der Saisonkomponente lokal mit trigonometrischen Polynomen

Saisonbereinigung: Etablierte Verfahren

Census X-12-ARIMA-Verfahren, mittlerweile X-13-ARIMA-SEATS

- Vom U.S. Bureau of the Census entwickelt
- Kostenloser Download unter
<https://www.census.gov/srd/www/x13as/>
- Kalender- und Ausreißerbereinigung
- Modellierung der Reihe durch Verbindung von Regressionsanalyse und ARIMA-Verfahren
- Schätzung der Saisonkomponente durch iterative Anwendung verschiedener gleitender Durchschnitte
- Diagnostika zur Überprüfung der Güte

Gliederung der Vorlesung


- 1) Einführung und Grundlagen
- 2) Klassische Zeitreihenanalyse
 - a) Trendbestimmung
 - b) Glättung von Zeitreihen durch Filter (lokale Trendbestimmung)
 - c) Saisonbereinigung
 - d) Prognosen, exponentielles Glätten
- 3) Modellierung von Reihen durch stochastische Prozesse
 - a) Autoregressive (AR) Modelle
 - b) Moving Average (MA) Modelle
 - c) ARMA Modelle
 - d) ARIMA Modelle

Prognosen

- Trendextrapolation: bei Polynomen kann außerhalb des Stützbereichs schief gehen → genau schauen! Konfidenzintervalle verfügbar, allerdings nur unter der Annahme von einem Gaußschen White Noise für Residuen.
- Exponentielles Glätten nach Holt-Winters
- ARIMA-Prognosen → später


Prognosen: Trendextrapolation

Globale Durchschnittstemperatur: Vorhersage



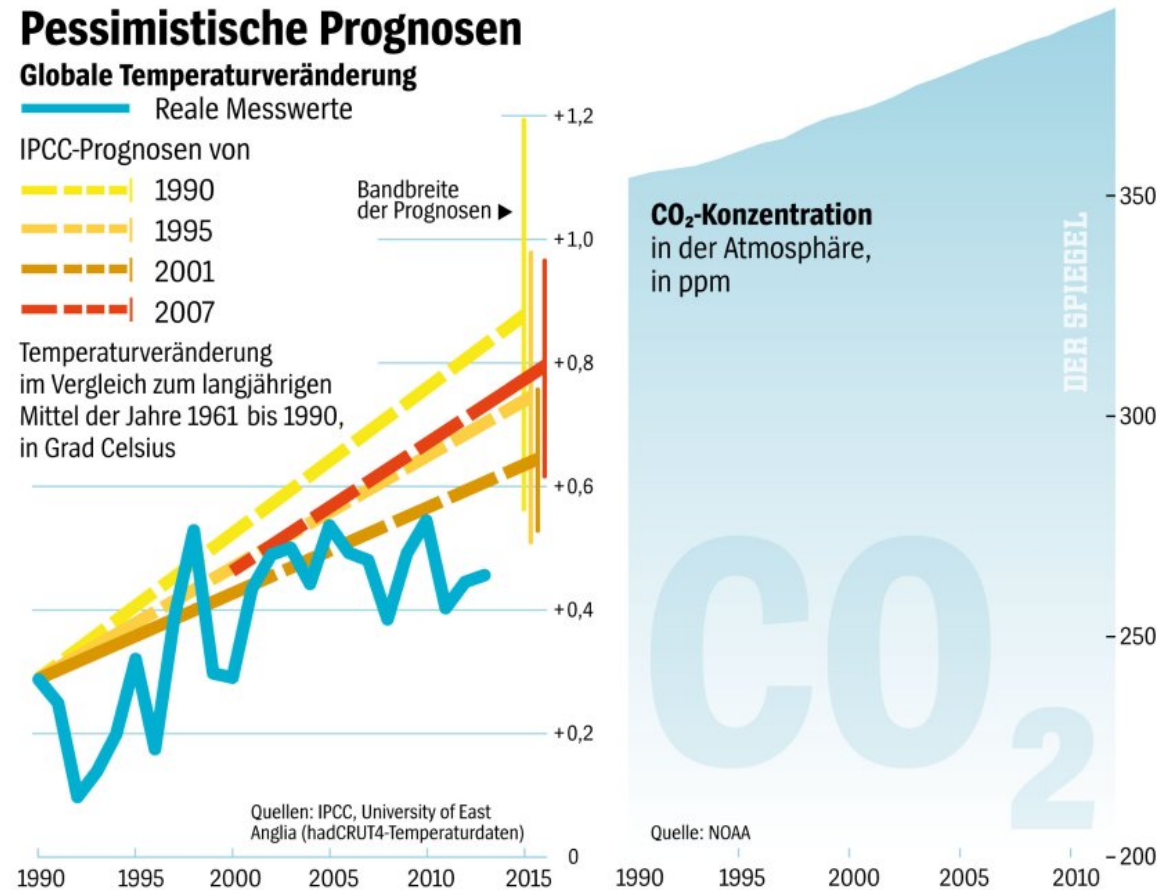
Linearer Trend zu niedrig...

Prognosen: Trendextrapolation




...außer man nimmt nur die letzten 50 Jahre.

Prognosen: Trendextrapolation



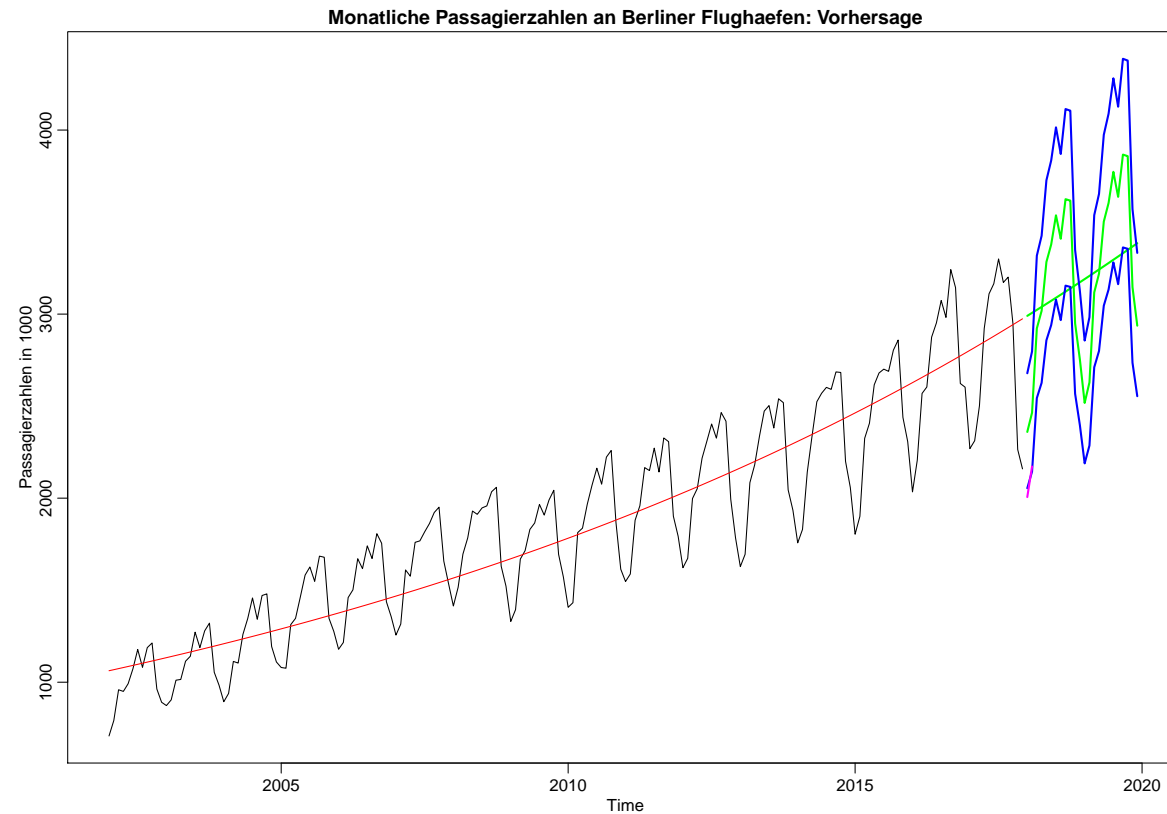
Prognosen: Trendextrapolation

Projektionen globaler Erwärmung



https://de.wikipedia.org/wiki/Globale_Erw%C3%A4rmung


Prognosen: Beispiel Passagierzahlen



Genaue Werte: [http:](http://www.berlin-airport.de/de/presse/basisinformationen/verkehrsstatistik/)


[//www.berlin-airport.de/de/presse/basisinformationen/verkehrsstatistik/](http://www.berlin-airport.de/de/presse/basisinformationen/verkehrsstatistik/).

Prognosen: Beispiel Passagierzahlen



Lineare Regression mit Saison-Dummies

Prognosen: Beispiel Passagierzahlen



Mit "stl"

Das einfache exponentielle Glätten

Ausgangspunkt ist ein einfaches Modell ohne Trend und Saison

$$X_t = \mu + \varepsilon_t$$

mit $\mu \in \mathbb{R}$ und White Noise (ε_k) . Die zugehörige Reihe ist $(x_t)_{t=1,\dots,N}$, und wir haben eine (Ein-Schritt-) Prognose \hat{x}_{N+1}^N für x_{N+1} .

Nun kommt eine neue Beobachtung x_{N+1} hinzu, und wir möchten die Prognose “updaten” → Ansatz:

$$\hat{x}_{N+2}^{N+1} = (1 - \alpha)\hat{x}_{N+1}^N + \alpha x_{N+1}$$

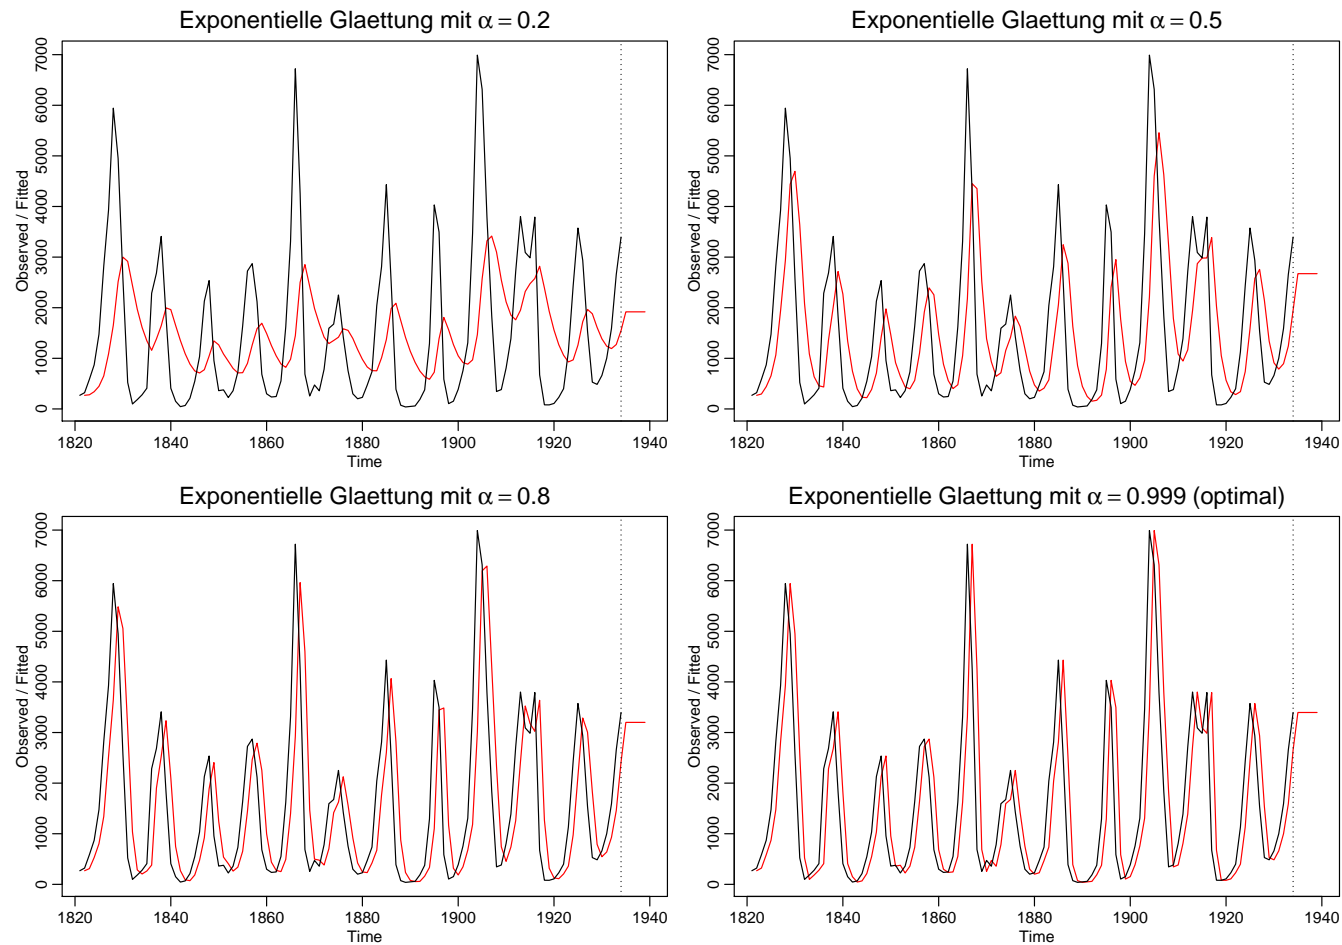
– ein **rekursiver Filter** aus der alten Prognose und dem neuen Wert.

Meist wird als Startwert $\hat{x}_1^1 := x_1$ gewählt.

$\alpha \in (0, 1)$ heißt **Glättungsparameter**.

Das einfache exponentielle Glätten

$\alpha \in (0, 1)$ heißt **Glättungsparameter**: Je kleiner α , desto stärker wird geglättet.



Das einfache exponentielle Glätten

$\alpha \in (0, 1)$ heißt **Glättungsparameter** und wird so gewählt, dass

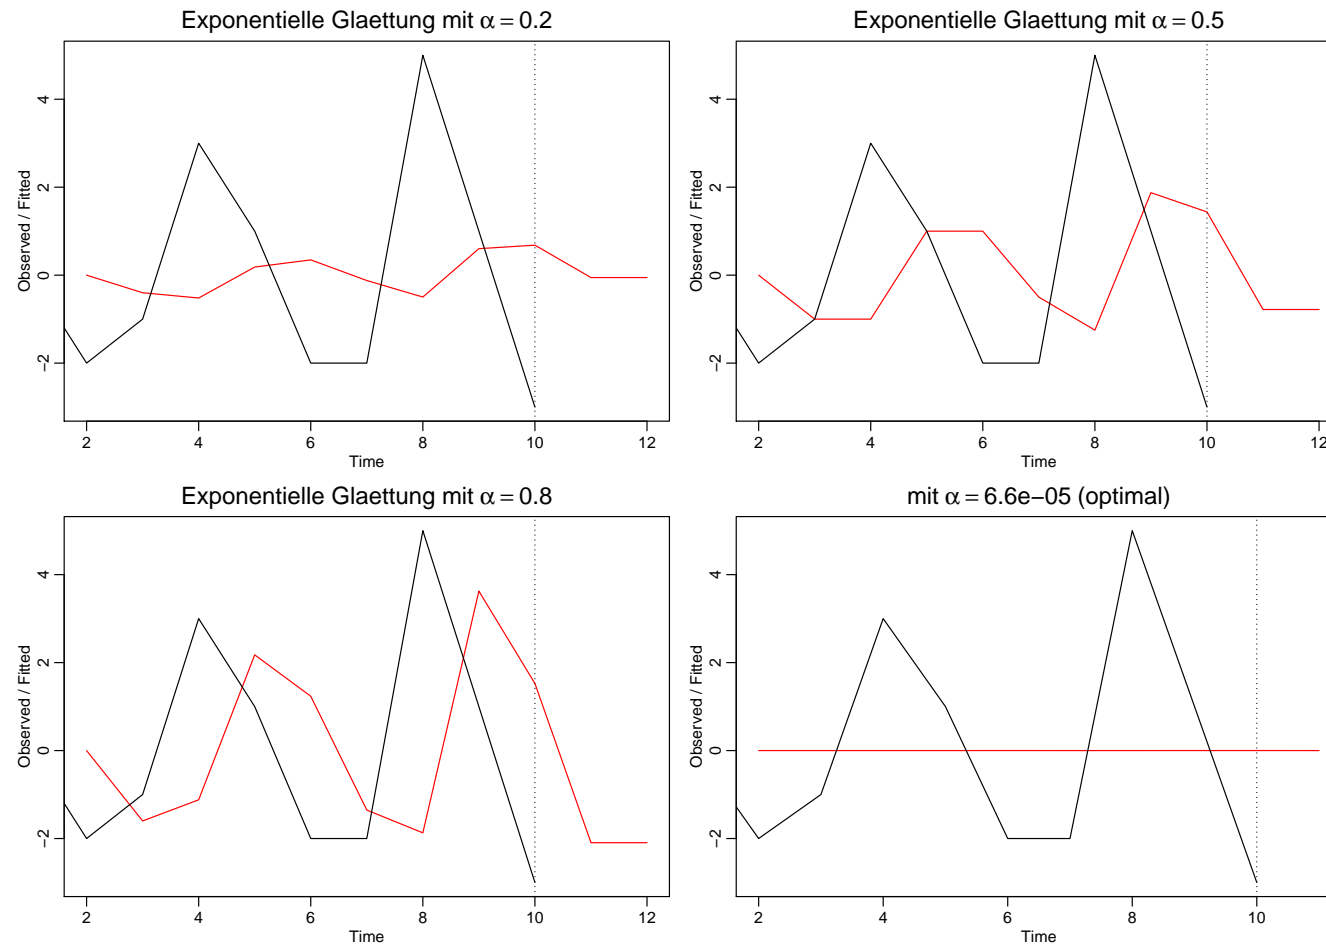
$$\sum_{t=m}^{N-1} (x_{t+1} - \hat{x}_1^t)^2 \xrightarrow{!} \min_{\alpha}.$$

(Die untere Summationsgrenze m soll den Effekt des Startwertes vernachlässigbar machen.) Meist reicht es die Werte $0.1, 0.2, \dots, 0.9$ für α auszuprobieren, R macht es automatisch.

Da das zugrundeliegende Modell eines mit einem konstantem Niveau ist, wird für h -Schritt Prognosen ($h > 1$) einfach die 1-Schritt-Prognose fortgeschrieben:

$$\hat{x}_{N+h}^N = \hat{x}_{N+1}^N.$$

Das einfache exponentielle Glätten



Das einfache exponentielle Glätten

```
#Annual Canadian Lynx trappings 1821-1934
#einfach
plot(lynx, main="Anzahl gefangener Luchse in Kanada 1821-1934")
(hwl2 = HoltWinters(lynx, alpha=.2, beta=F, gamma=F))
(hwl5 = HoltWinters(lynx, alpha=.5, beta=F, gamma=F))
(hwl8 = HoltWinters(lynx, alpha=.8, beta=F, gamma=F))
(hwl = HoltWinters(lynx, beta=F, gamma=F))
mean(lynx)
(hwl1 = HoltWinters(lynx, alpha=.1, beta=F, gamma=F))
p2=predict(hwl2, n.ahead = 5)
p5=predict(hwl5, n.ahead = 5)
p8=predict(hwl8, n.ahead = 5)
p=predict(hwl, n.ahead = 5)
par(mfrow=c(2,2), mar=c(3,2.5,2,1), cex.main=1.5)
plot(hwl2, p2, main=as.expression(bquote("Exponentielle Glaettung mit" ~ alpha == 0.2)))
plot(hwl5, p5, main=as.expression(bquote("Exponentielle Glaettung mit" ~ alpha == 0.5)))
plot(hwl8, p8, main=as.expression(bquote("Exponentielle Glaettung mit" ~ alpha == 0.8)))
plot(hwl, p, main=as.expression(bquote("Exponentielle Glaettung mit" ~ alpha == 0.999~ "(optimal)"))))

#mit Trend
(hwlt = HoltWinters(lynx, gamma=F))
pt=predict(hwlt, n.ahead = 5)
plot(hwlt, pt, main=as.expression(bquote("Exponentielle Glaettung mit Trend"))))
#wocher der Trend?
diff(lynx)[1]
(hwlto = HoltWinters(lynx, gamma=F, b.start=0))
pto=predict(hwlto, n.ahead = 5)
plot(hwlto, pto, main=as.expression(bquote("Exponentielle Glaettung mit Trend"))))
```


Exponentielles Glätten nach Holt

Nun betrachten wir ein Modell mit linearem Trend und ohne Saison

$$X_t = m_t + \varepsilon_t = a + bt + \varepsilon_t.$$

→ 2 Glättungsparameter: α zur Anpassung des Trends m_t und β zur Anpassung der Steigung b . Rekursion:

$$\hat{b}_t = (1 - \beta)\hat{b}_{t-1} + \beta(\hat{m}_{t-1} - \hat{m}_{t-2}),$$

$$\hat{m}_t = (1 - \alpha)(\hat{m}_{t-1} + \hat{b}_t) + \alpha x_t, \quad t = 2, 3, \dots, N.$$


h -Schritt-Prognose:

$$\hat{x}_{N+h}^N = \hat{m}_N + \hat{b}_N \cdot h, \quad h = 1, 2, \dots$$

Startwerte: Z.B.

$$\hat{m}_1 = x_1, \quad \hat{m}_2 = x_2, \quad \hat{b}_1 = x_2 - x_1, \quad \hat{b}_2 = \hat{b}_1.$$

Exponentielles Glätten nach Holt



Exponentielles Glätten nach Holt

```
> (hwlt = HoltWinters(lynx, gamma=F))
Holt-Winters exponential smoothing with trend and without seasonal component.

Call:
HoltWinters(x = lynx, gamma = F)

Smoothing parameters:
alpha: 1
beta : 0
gamma: FALSE

Coefficients:
[,1]
a 3396
b 52
```

Woher der Trend?

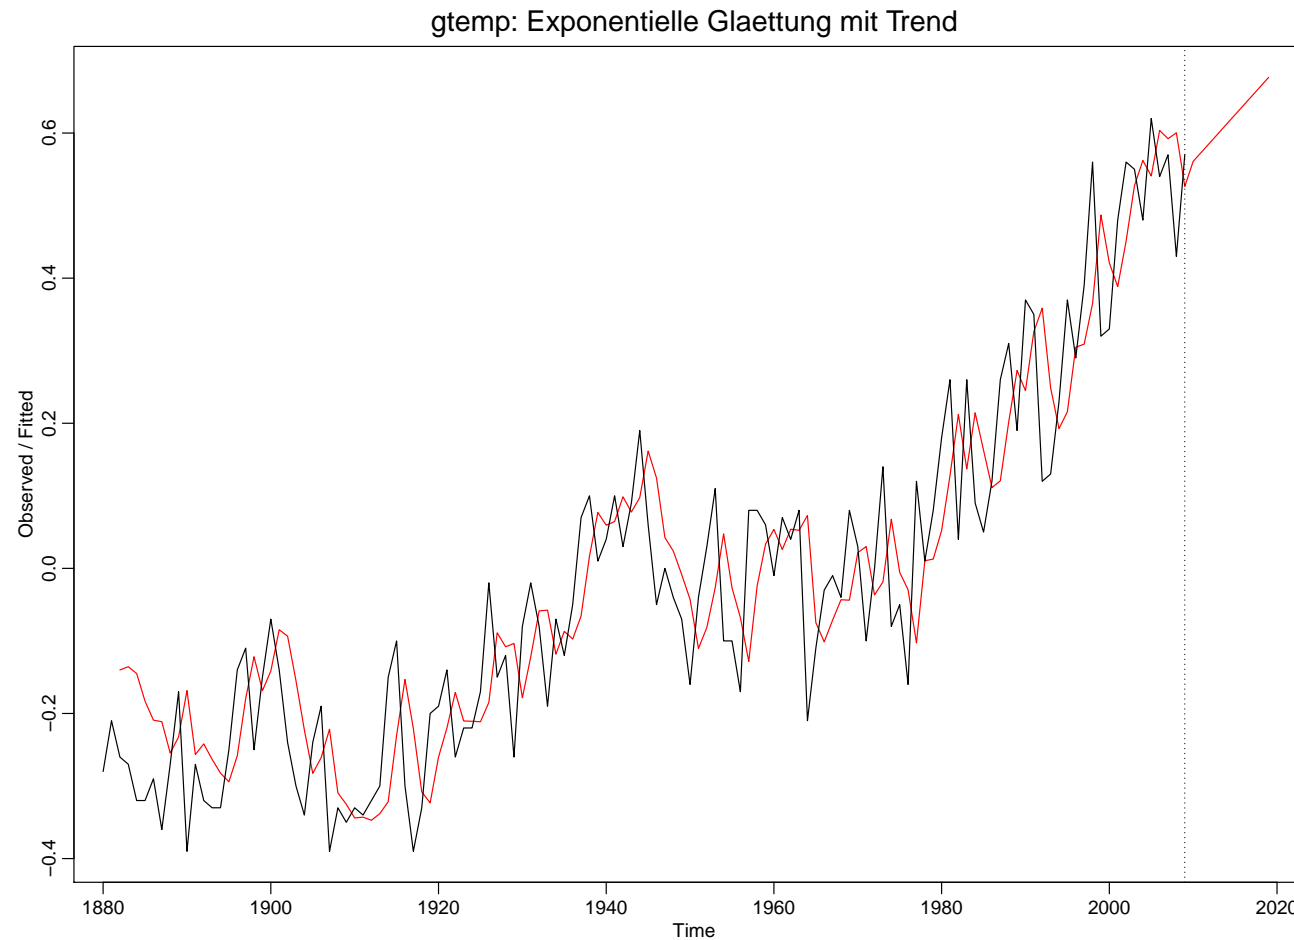
```
> diff(lynx)[1]
[1] 52
> (hwlt0 = HoltWinters(lynx, gamma=F, b.start=0))
Holt-Winters exponential smoothing with trend and without seasonal component.

Call:
HoltWinters(x = lynx, gamma = F, b.start = 0)

Smoothing parameters:
alpha: 1
beta : 0
gamma: FALSE

Coefficients:
[,1]
a 3396
b 0
```

Exponentielles Glätten nach Holt



https://de.wikipedia.org/wiki/Globale_Erw%C3%A4rmung

Exponentielles Glätten nach Holt

```
> (hwlt = HoltWinters(gtemp, gamma=F))
```

Holt-Winters exponential smoothing with trend and without seasonal component.

Call:

```
HoltWinters(x = gtemp, gamma = F)
```

Smoothing parameters:

alpha: 0.4967435

beta : 0.09964769

gamma: FALSE

Coefficients:

[,1]

a 0.5480703

b 0.0128656

#oder

```
(forecasts=forecast.HoltWinters(hwlt, h=10))
```

```
plot.forecast(forecasts)
```


```
res=na.omit(forecasts$residuals)
```

```
plot(res)
```


```
acf(res,30)
```

```
Box.test(res, lag=20, type="Ljung-Box", fitdf=2)
```

Exponentielles Glätten nach Holt



Exponentielles Glätten nach Holt



Exponentielles Glätten nach Holt-Winters

Nun betrachten wir ein (additives) Modell mit linearem Trend und Saison (Periode s)

$$X_t = m_t + s_t + \varepsilon_t = a + bt + s_t + \varepsilon_t.$$

→ 3 Glättungsparameter: α , β wie vorher und γ zur Anpassung der Saison. Rekursion:

$$\hat{b}_t = (1 - \beta)\hat{b}_{t-1} + \beta(\hat{m}_{t-1} - \hat{m}_{t-2}),$$

$$\hat{m}_t = (1 - \alpha)(\hat{m}_{t-1} + \hat{b}_t) + \alpha(x_t - \hat{s}_{t-s})$$

$$\hat{s}_t = (1 - \gamma)\hat{s}_{t-s} + \gamma(x_t - \hat{m}_t), \quad t = s + 1, \dots, N.$$

h -Schritt-Prognose:

$$\hat{x}_{N+h}^N = \hat{m}_N + \hat{b}_N \cdot h + \hat{s}_{t+h-s}, \quad h = 1, 2, \dots$$

Exponentielles Glätten nach Holt-Winters

Rekursion

$$\hat{b}_t = (1 - \beta)\hat{b}_{t-1} + \beta(\hat{m}_{t-1} - \hat{m}_{t-2}),$$

$$\hat{m}_t = (1 - \alpha)(\hat{m}_{t-1} + \hat{b}_t) + \alpha(x_t - \hat{s}_{t-s})$$

$$\hat{s}_t = (1 - \gamma)\hat{s}_{t-s} + \gamma(x_t - \hat{m}_t), \quad t = s + 1, \dots, N$$

kann erst ab $t = s + 1$ beginnen, Startwerte Z.B.

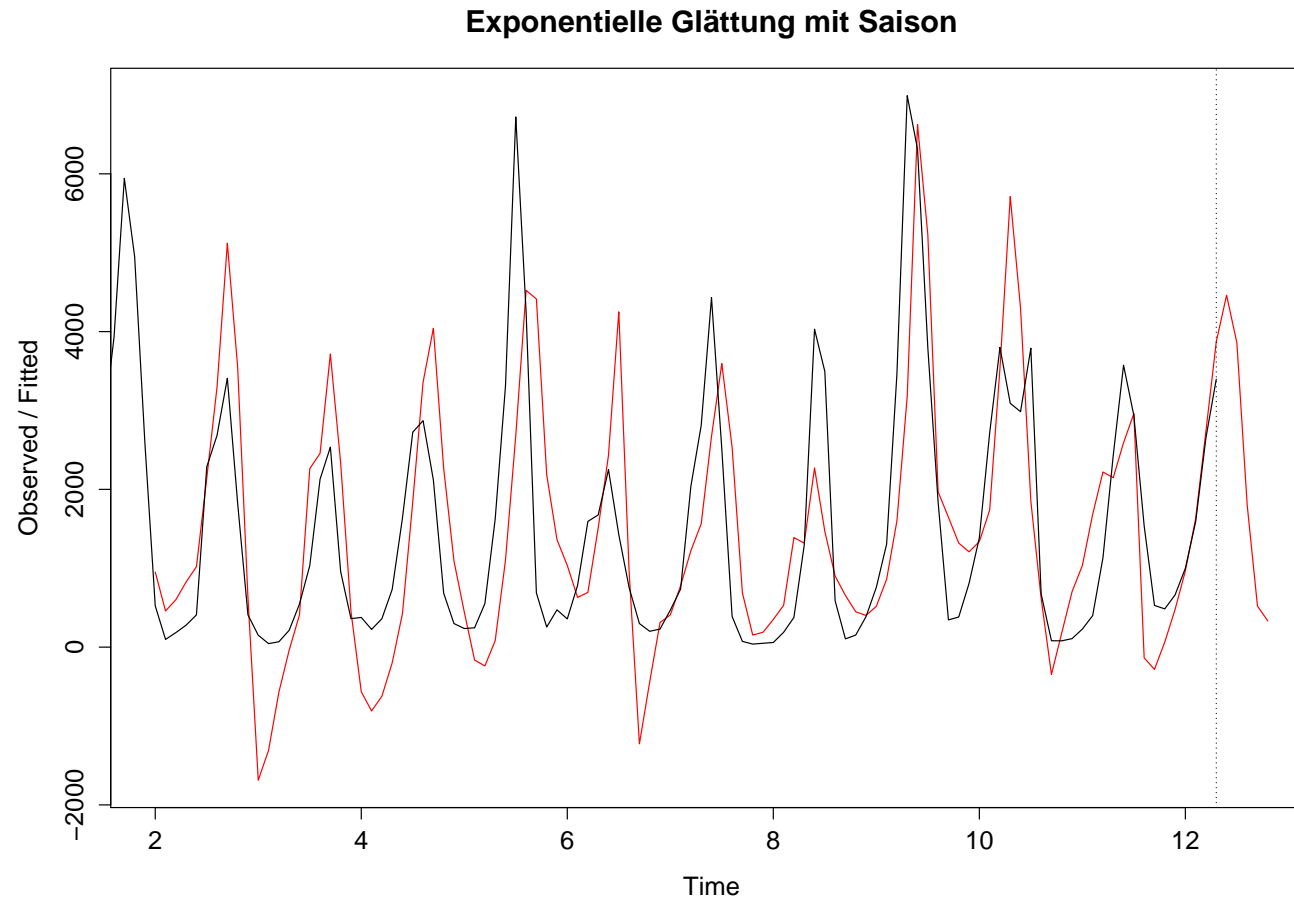
$$\hat{m}_{s-1} = \hat{m}_s = \overline{x_s} = \frac{1}{s} \sum_{k=1}^s x_k, \quad \hat{b}_s = 0, \quad \hat{s}_t = x_t - \overline{x_s}, \quad t = 1, \dots, s$$

Variante: Multiplikatives Modell mit linearem Trend und Saison

$$X_t = (a + bt) \cdot s_t \cdot \varepsilon_t$$

→ Die Formeln entsprechend anpassen (s. Help zu “HoltWinters” in R).

Exponentielles Glätten nach Holt-Winters



Exponentielles Glätten nach Holt-Winters

```
#mit Saison  
lynxn=ts(lynx, frequency = 10)  
(hwls = HoltWinters(lynxn, beta=F))  
ps=predict(hwls, n.ahead = 10)  
plot(hwls,ps, main="Exponentielle Glättung mit Saison")
```

Exponentielles Glätten nach Holt-Winters

